

# Simpson's Paradox

Consideriamo due trattamenti per i calcoli renali: **Trattamento A** e **Trattamento B**.

I pazienti sono classificati in due gruppi:

- con **calcoli piccoli**,
  - con **calcoli grandi**.
- 
- **Trattamento A** è più efficace sui calcoli piccoli.
  - **Trattamento A** è anche più efficace sui calcoli grandi.

Il Trattamento A è superiore in ogni gruppo.

Tuttavia, se si **ignora la classificazione** e si calcola la **media globale dei successi**, il Trattamento B può risultare **più efficace nel totale**. Come è possibile?

# Simpson's Paradox

|                 | Trattamento A | Trattamento B |
|-----------------|---------------|---------------|
| calcoli piccoli | 90% efficace  | 80% efficace  |
| calcoli grandi  | 60% efficace  | 50% efficace  |
| media globale   | 63% efficace  | 77% efficace  |

# Simpson's Paradox

|                 | Trattamento A                                         | Trattamento B                                         |
|-----------------|-------------------------------------------------------|-------------------------------------------------------|
| calcoli piccoli | <b>90% efficace</b><br>(successo in 90 casi su 100)   | <b>80% efficace</b><br>(successo in 800 casi su 1000) |
| calcoli grandi  | <b>60% efficace</b><br>(successo in 600 casi su 1000) | <b>50% efficace</b><br>(successo in 50 casi su 100)   |
| media globale   | <b>63% efficace</b><br>(successo in 690 casi su 1100) | <b>77% efficace</b><br>(successo in 850 casi su 1100) |

# Simpson's Paradox

|                 | Trattamento A                                         | Trattamento B                                         |
|-----------------|-------------------------------------------------------|-------------------------------------------------------|
| calcoli piccoli | <b>90% efficace</b><br>(successo in 90 casi su 100)   | <b>80% efficace</b><br>(successo in 800 casi su 1000) |
| calcoli grandi  | <b>60% efficace</b><br>(successo in 600 casi su 1000) | <b>50% efficace</b><br>(successo in 50 casi su 100)   |
| media globale   | <b>63% efficace</b><br>(successo in 690 casi su 1100) | <b>77% efficace</b><br>(successo in 850 casi su 1100) |

**Il trattamento B è migliore?**

No! A è migliore sia sui piccoli, sia sui grandi calcoli. Quindi, non può che essere il migliore!

# Simpson's Paradox

- 1 I **contributi principali al risultato complessivo** provengono dai quadranti [grandi, A] e [piccoli, B], poiché in entrambi i casi si tratta di gruppi con **1000 pazienti ciascuno**.
- 2 Tuttavia, il gruppo [piccoli, B] mostra una **percentuale di successo complessiva più alta** rispetto a [grandi, A], **non perché il trattamento B sia migliore**, ma perché la **differenza tra piccoli e grandi calcoli** (facilità del caso clinico) ha un **peso statistico molto maggiore** rispetto alla differenza tra i trattamenti.

## Morale:

Le medie aggregate (globali) possono raccontare una storia diversa (**e sbagliata**) se non si tiene conto dei sottogruppi che le compongono. La media globale è fortemente influenzata dal confronto tra l'efficacia di A sui casi più difficili e l'efficacia di B sui casi più facili.

Un algoritmo A può sembrare peggiore di un algoritmo B, nel totale degli scenari, semplicemente perché affronta i casi più difficili.

# Esercizio 1

Abbiamo calzini di **due colori**: **rosso** e **blu**. Ce ne sono infiniti per ciascun colore.  
A ogni estrazione prendiamo un calzino a caso (rossi e blu *equiprobabili, indipendenti*).

Qual è il **numero atteso di estrazioni** necessario per ottenere una **coppia** (due dello stesso colore)?

$T$  = numero di estrazioni fino alla prima coppia.

# Esercizio 1

$T$  = numero di estrazioni fino alla prima coppia.

Alla **prima** estrazione non abbiamo ancora una coppia.

Definiamo l'evento  $F$  = “alla seconda estrazione otteniamo una coppia”.



$$E[T] = E[T \mid F] \cdot \Pr\{F\} + E[T \mid \bar{F}] \cdot \Pr\{\bar{F}\} = 2 \cdot \frac{1}{2} + 3 \cdot \frac{1}{2} = \frac{5}{2}.$$

# Esercizio 2

Consideriamo un **grafo casuale** con  $n$  vertici, dove ogni coppia di vertici è collegata da un arco con probabilità  $p$ , *indipendentemente* dalle altre coppie.

1. Qual è il **valore atteso del numero di archi** del grafo?
2. Qual è la **distribuzione del grado** di un vertice  $i$ ?



# Esercizio 2

Il numero dei possibili archi è  $\binom{n}{2}$ .

Per ogni coppia di vertici  $i, j$ , sia  $X_{ij} = 1$  se l'arco  $(i, j)$  è presente, 0 altrimenti.

Ogni  $X_{ij}$  è **Bernoulliana** con  $P\{X_{ij} = 1\} = p, \quad E[X_{ij}] = p$

Il numero di archi del grafo è  $X = \sum_{i < j} X_{ij}$ .

Applicando la **linearità della media**:

$$E[X] = \sum_{i < j} E[X_{ij}] = \binom{n}{2} p = \frac{n(n-1)}{2} \cdot p.$$

# Esercizio 2

Il vertice  $i$  può collegarsi a ciascuno degli altri  $n - 1$  vertici.

Definiamo per ciascun altro vertice  $j$  la variabile  $Y_j = \begin{cases} 1 & \text{se l'arco } (i, j) \text{ è presente;} \\ 0 & \text{altrimenti.} \end{cases}$

Ogni  $Y_j$  è Bernoulliana con parametro  $p$ .

Il grado del vertice è definito dalla v.c.  $D = \sum_{j \neq i} Y_j$ .

Poiché le  $Y_j$  sono anche indipendenti,  $D \sim \text{Binomiale}(n - 1, p)$ .

# Esercizio 3

Ci viene detto che la dimensione media dei file in un database è di 6 KB.

Spiegare perché, in base alla definizione di valore atteso, ne consegue che la **probabilità** che un file sia più grande di 12 KB è minore di 0,5.

# Esercizio 3

Ci viene detto che la dimensione media dei file in un database è di 6 KB.

Spiegare perché, in base alla definizione di valore atteso, ne consegue che la **probabilità** che un file sia più grande di 12 KB è minore di 0,5.

$$A = \{X > 12\}, \quad \bar{A} = \{X \leq 12\}.$$

$$6 = E[X] = E[X \mid A] \cdot P\{A\} + E[X \mid \bar{A}] \cdot P\{\bar{A}\}$$

$$> 12 \cdot P\{A\} + 0 \cdot P\{\bar{A}\} = 12 \cdot P\{A\}.$$

$$P\{A\} < \frac{1}{2}.$$

# Esercizio 4

Ci sono  $n$  persone in una stanza.

Una persona si dice “**felice**” se **condivide il compleanno** con almeno un'altra persona presente nella stanza. Qual è il **numero atteso di persone felici**?

# Esercizio 4

Ci sono  $n$  persone in una stanza.

Una persona si dice “**felice**” se **condivide il compleanno** con almeno un'altra persona presente nella stanza. Qual è il **numero atteso di persone felici**?

$$X_i = \begin{cases} 1 & \text{se felice} \\ 0 & \text{altrimenti} \end{cases}$$

il numero di persone felici è la v.c.  $X = X_1 + X_2 + \dots + X_n$

$$E[X] = \sum_{i=1}^n E[X_i] = n \cdot E[X_1]$$

$$E[X_1] = P\{\text{persona 1 felice}\} = 1 - P\{\text{persona 1 unica con il suo compleanno}\} = 1 - \left(\frac{364}{365}\right)^{n-1}.$$

$$E[X] = n \left[ 1 - \left(\frac{364}{365}\right)^{n-1} \right].$$

# Capitolo 5

## Varianza e Momenti

# Momenti di Ordine Superiore

**Def:** Il momento di ordine  $k$  (o anche  $k$ -esimo momento) della v.c.  $X$  è

$$E[X^k] = \sum_x x^k \cdot P\{X = x\}$$

$E[X]$  è il momento di ordine 1 (o primo momento) di  $X$ .



# Momenti di Ordine Superiore

Possiamo dire

$$E[X^2] = E[X] \cdot E[X]?$$



No. Perché?

Perché ovviamente  $X$  non è indipendente da  $X$ .

# Momenti di Ordine Superiore

Esempio:

$X \sim \text{Geometrica}(p).$

Vogliamo derivare  $E[X^2]$ .

$$E[X^2] = \sum_{i=1}^{\infty} i^2 p_X(i) = \sum_{i=1}^{\infty} i^2 (1-p)^{i-1} \cdot p$$

Non sembra  
facile da  
calcolare.

Proviamo via  
condizionamento



# 2° Momento della Geometrica

$X \sim \text{Geometrica}(p)$ .



Condizioniamo sul valore del primo lancio,  $Y$ .

$$\begin{aligned} E[X^2] &= E[X^2 | Y = 1] \cdot P\{Y = 1\} + E[X^2 | Y = 0] \cdot P\{Y = 0\} \\ &= 1 \cdot p + E[X^2 | Y = 0] \cdot (1 - p) \end{aligned}$$

# 2° Momento della Geometrica

$X \sim \text{Geometrica}(p)$ .



Condizioniamo sul valore del primo lancio,  $Y$ .

$$E[X^2] = E[X^2 | Y = 1] \cdot P\{Y = 1\} + E[X^2 | Y = 0] \cdot P\{Y = 0\}$$

$$= 1 \cdot p + \underbrace{E[X^2 | Y = 0]}_{\substack{[X | Y = 0] \stackrel{d}{=} X + 1 \\ [X^2 | Y = 0] \stackrel{d}{=} (X + 1)^2}} \cdot (1 - p)$$

$$[X | Y = 0] \stackrel{d}{=} X + 1$$

$$[X^2 | Y = 0] \stackrel{d}{=} (X + 1)^2$$

$$= 1 \cdot p + E[(1 + X)^2] \cdot (1 - p)$$

# 2° Momento della Geometrica

$X \sim \text{Geometrica}(p)$ .



Condizioniamo sul valore del primo lancio,  $Y$ .

$$E[X^2] = E[X^2 | Y = 1] \cdot P\{Y = 1\} + E[X^2 | Y = 0] \cdot P\{Y = 0\}$$

$$= 1 \cdot p + E[X^2 | Y = 0] \cdot (1 - p)$$

$$= 1 \cdot p + E[(1 + X)^2] \cdot (1 - p)$$

$$= 1 \cdot p + E[1 + 2X + X^2] \cdot (1 - p)$$

$$= 1 \cdot p + (1 + 2E[X] + E[X^2]) \cdot (1 - p)$$

# 2° Momento della Geometrica

$X \sim \text{Geometrica}(p)$ .



Condizioniamo sul valore del primo lancio,  $Y$ .

$$\begin{aligned} E[X^2] &= E[X^2 | Y = 1] \cdot P\{Y = 1\} + E[X^2 | Y = 0] \cdot P\{Y = 0\} \\ &= 1 \cdot p + (1 + 2E[X] + E[X^2]) \cdot (1 - p) \\ &= p + 1 - p + \frac{2(1-p)}{p} + E[X^2] - p \cdot E[X^2] \\ &= 1 + \frac{2(1-p)}{p} + E[X^2] - p \cdot E[X^2] \\ &\Rightarrow p \cdot E[X^2] = 1 + \frac{2(1-p)}{p} = \frac{p+2-2p}{p} \end{aligned}$$

Risultato:

$$E[X^2] = \frac{2-p}{p^2}$$

# Varianza

Def: La **varianza** della v.c.  $X$  è il valore atteso del **quadrato dello scarto** di  $X$  dalla media.

$$Var(X) = E[(X - E[X])^2]$$

La varianza misura la dispersione di una variabile casuale attorno al suo valore atteso.

## Esempio.


Microsoft e una Startup hanno entrambe un valore atteso di guadagno pari a 100000 dollari.

I guadagni di Microsoft possono oscillare tra 90000 e 110000 dollari, mentre per la startup possono variare da 0 a 1 milione di dollari.

La **varianza** “cattura” questa **differenza di rischio** (più alto per Startup).

# Varianza

$$\text{Var}(X) = E[(X - E[X])^2]$$



$$\text{Var}(X) = \frac{d_1^2 + d_2^2 + d_3^2 + d_4^2}{4}$$



# Varianza

Come è  $\text{Var}(-X)$   
rispetto a  $\text{Var}(X)$ ?

$$E[-X] = -E[X]$$

$$\text{Var}(-X) = E\left[\left((-X) - E[-X]\right)^2\right] = E[(-X + E[X])^2]$$

$$= E[(X - E[X])^2] = \text{Var}(X)$$

**Il segno non cambia la varianza:**

riflettere  $X$  attorno a 0 non altera la dispersione attorno alla sua media.

# Fattore di rischio tra Microsoft e una Startup

Microsoft  $\rightarrow$  Earnings =  $10^5$

$$\text{Startup} = \begin{cases} 10^7 & \text{p. 1\%} \\ 0 & \text{p. 99\%} \end{cases}$$

Determiniamo media e varianza in ciascun caso.

$$E[\text{Money at Microsoft}] = 10^5$$

$$\text{Var}(\text{Money at Microsoft}) = 0$$

$$E[\text{Money at Startup}] = 10^5$$

$$\text{Var}(\text{Money at Startup})$$

$$= E[(\text{Money} - 10^5)^2]$$

$$= (10^7 - 10^5)^2 \cdot 0.01 + (0 - 10^5)^2 \cdot 0.99$$

$$\approx 10^{14} \cdot 0.01 + 10^{10} \cdot 0.99 \approx 10^{12}$$

# Varianza della Bernoulli( $p$ )

$$X = \text{valore del lancio} = \begin{cases} 1 & \text{prob. } p \\ 0 & \text{altrim.} \end{cases}$$



Probabilità  $p$   
che esca *testa*.

$$\begin{aligned} \text{Var}(X) &= E[(X - p)^2] \\ &= E[X^2 - 2Xp + p^2] \\ &= E[X^2] - 2pE[X] + p^2 \\ &= p - 2p \cdot p + p^2 \\ &= p - p^2 = p(1 - p) \end{aligned}$$

Ricordiamo:  
 $E[X] = p$

Ovviamente anche  
 $E[X^2] = p$

Ricordiamo!  
Varianza  
Bernoulli( $p$ )  
è  $p(1 - p)$ .

# Condizionare sulla Varianza non è Corretto

$$X = \text{valore del lancio} = \begin{cases} 1 & \text{prob. } p \\ 0 & \text{altrim.} \end{cases}$$



Probabilità  $p$   
che esca *testa*.

$$\begin{aligned} \text{Var}(X) &= \text{Var}(X|X=1) \cdot p + \text{Var}(X|X=0) \cdot (1-p) \\ &= 0 \cdot p + 0 \cdot (1-p) \\ &= 0 \end{aligned}$$

**Nessun teorema ci autorizza  
a condizionare sulla varianza.**

**Abbiamo solo un teorema che  
ci autorizza a condizionare sul  
valore atteso.**

# Definizioni Alternative di Varianza?

$$E[X - E[X]]$$

Non va bene.  
Perché?

# Definizioni Alternative di Varianza?

$$E[|X - E[X]|]$$

Potrebbe andar bene,  
ma perdiamo la  
linearità.

# Definizioni Alternative di Varianza?

$$\sqrt{E[(X - E[X])^2]}$$

Questa va bene. E  
infatti ha un  
nome.

# Deviazione Standard di X

**Def**: La **deviazione standard** di una v.c.  $X$  è:

$$\sigma_X = \mathbf{std}(X) = \sqrt{E[(X - E[X])^2]}$$

Possiamo scrivere:

$$\mathbf{Var}(X) = \sigma_X^2$$



# La necessità di una diversa metrica

Supponiamo di misurare una quantità, prima in cm ( $X$ ) e poi in mm ( $Y$ ):

$$X = \begin{cases} 1 & \text{p. } \frac{1}{3} \\ 2 & \text{p. } \frac{1}{3} \\ 3 & \text{p. } \frac{1}{3} \end{cases}$$

$$Y = \begin{cases} 10 & \text{p. } \frac{1}{3} \\ 20 & \text{p. } \frac{1}{3} \\ 30 & \text{p. } \frac{1}{3} \end{cases}$$

Ci aspetteremmo la stessa varianza, visto che sono la stessa quantità, ma:

$$\mathit{Var}(X) = \frac{2}{3}$$

$$\mathit{Var}(Y) = \frac{200}{3}$$

Serve una  
metrica  
diversa!

# Coefficiente di variazione quadratico

**Def 5.6:** Il coefficiente di variazione quadratico di una v.c.  $X$  è:

$$C_X^2 = \frac{Var(X)}{E[X]^2}$$

$$X = \begin{cases} 1 & \text{p. } \frac{1}{3} \\ 2 & \text{p. } \frac{1}{3} \\ 3 & \text{p. } \frac{1}{3} \end{cases}$$

$$Y = \begin{cases} 10 & \text{p. } \frac{1}{3} \\ 20 & \text{p. } \frac{1}{3} \\ 30 & \text{p. } \frac{1}{3} \end{cases}$$

È  
invariante  
rispetto  
alla scala!

$$E[X] = 2 \quad Var(X) = \frac{2}{3}$$

$$C_X^2 = \frac{1}{6}$$

$$E[Y] = 20 \quad Var(Y) = \frac{200}{3}$$

$$C_Y^2 = \frac{1}{6}$$

# Definizione Equivalente di Varianza

**Teorema 5.7:**

$$\mathit{Var}(X) = E[X^2] - E[X]^2$$

$$\mathit{Var}(X) = E[(X - E[X])^2]$$

$$= E[X^2 - 2XE[X] + E[X]^2]$$

$$= E[X^2] - 2E[X]E[X] + E[X]^2$$

$$= E[X^2] - E[X]^2$$

# Linearità della Varianza

**Teorema 5.8:** Siano  $X$  e  $Y$  due v.c. con  $X \perp Y$ . Allora

$$\mathbf{Var}(X + Y) = \mathbf{Var}(X) + \mathbf{Var}(Y)$$

$$\mathbf{Var}(X + Y) = E[(X + Y)^2] - E[X + Y]^2$$

$$= E[X^2] + E[Y^2] + 2E[XY] - E[X]^2 - E[Y]^2 - 2E[X]E[Y]$$

$$= \mathbf{Var}(X) + \mathbf{Var}(Y) + \underbrace{2E[XY] - 2E[X]E[Y]}_{0}$$

$$= \mathbf{Var}(X) + \mathbf{Var}(Y)$$

Perché  $X \perp Y$

# Varianza della Binomiale( $n, p$ )



$X = X_1 + X_2 + \dots + X_n$ , dove  $X_i \sim \text{Bernoulli}(p)$

Le  $X_i$  sono  
indipendenti.

**Applichiamo la linearità della Varianza (siamo autorizzati):**

$$\begin{aligned} \text{Var}(X) &= \text{Var}(X_1) + \text{Var}(X_2) + \dots + \text{Var}(X_n) \\ &= p(1 - p) + p(1 - p) + \dots + p(1 - p) = np(1 - p) \end{aligned}$$

Ricordare!  
Varianza  
Binomiale( $n, p$ )  
è  $np(1 - p)$ .

# Somma vs Copia

Siano  $X_1$  e  $X_2$  due v.c. indipendenti e identicamente distribuite (i.i.d.). Sia  $X$  un'altra v.c. tale che  $X_1 \sim X_2 \sim X$ .

Definiamo:

$$Y = X_1 + X_2$$

$$Z = 2X$$

$Y$  e  $Z$  hanno la stessa distribuzione?

NO. Se ad esempio  $X_1$ ,  $X_2$  e  $X$  sono  $\sim$ Bernoulli. Per  $Y$  i valori possibili sono 0, 1 o 2. Per  $X$  sono 0 oppure 2.

# Somma vs Copia


Siano  $X_1$  e  $X_2$  due v.c. indipendenti e identicamente distribuite (i.i.d.). Sia  $X$  un'altra v.c. tale che  $X_1 \sim X_2 \sim X$ .

$$Y = X_1 + X_2$$

$$Z = 2X$$

$$E[Y] = E[Z] = 2E[X]$$

$$\text{Var}(Y) = \text{Var}(X_1) + \text{Var}(X_2) = 2 \text{Var}(X)$$



Perché  $Y$  ha una varianza più bassa di  $Z$ ?

$$\text{Var}(Z) = E[(2X)^2] - E[2X]^2 = 4E[X^2] - (2E[X])^2 = 4 \text{Var}(X)$$

# Somma vs Copia

Siano  $X_1$  e  $X_2$  due v.c. indipendenti e identicamente distribuite (i.i.d.). Sia  $X$  un'altra v.c. tale che  $X_1 \sim X_2 \sim X$ .

$$Y = X_1 + X_2$$

$$Z = 2X$$

$Z = 2X$  “raddoppia” **ogni singola realizzazione** di  $X \rightarrow$  le deviazioni dalla media si **raddoppiano sempre**.

$Y = X_1 + X_2$  somma **due v.c. indipendenti**  $\rightarrow$  le deviazioni si **combinano indipendentemente a caso**, e talvolta si compensano.