

Capitolo 18

Limiti di coda

Code

Def: La **coda** di una variabile casuale X è $P\{X > x\}$.

Esempi che mostrano perché ci interessano le code (tails):

- Frazione di job che restano in coda per più di 24 ore
- Frazione di pacchetti che trovano il buffer del router pieno
- Frazione di bucket dell'hash che contengono più di 10 elementi



Purtroppo, determinare la coda anche di variabili casuali semplici è spesso difficile — molto più che calcolarne la media!

Esempi di code

Supponiamo di distribuire n job tra n server in modo casuale.
Qual è la probabilità che un determinato server riceva **almeno k job**?

$$X \sim \text{Binomiale}(n, p)$$

$$P\{X \geq k\} = \sum_{i=k}^n \binom{n}{i} p^i (1-p)^{n-i}$$

Non si
conoscono
forme chiuse per
questa

Esempi di code

I job arrivano a un data center secondo un processo di Poisson con tasso λ job/ora. Qual è la probabilità che **arrivino almeno k job durante la prima ora?**

$$X \sim \text{Poisson}(\lambda)$$

$$P\{X \geq k\} = \sum_{i=k}^{\infty} e^{-\lambda} \cdot \frac{\lambda^i}{i!}$$



Non si
conoscono
forme chiuse per
questa

Limiti di coda



Invece di calcolare direttamente le code, ne ricaveremo **limiti superiori**, detti **tail bounds** (limiti di coda)!

$$P\{X \geq k\} = \sum_{i=k}^{\infty} e^{-\lambda} \cdot \frac{\lambda^i}{i!}$$

$$P\{X \geq k\} = \sum_{i=k}^n \binom{n}{i} p^i (1-p)^{n-i}$$

Un **limite superiore** su $P\{X \geq k\}$ si chiama **tail bound** (*limite di coda*).

Un **limite superiore** su $P\{|X - \mu| \geq k\}$, dove $\mu = E[X]$, si chiama **concentration bound** o **disuguaglianza di concentrazione**.

Esempio guida



Svilupperemo via via **limiti di coda sempre più precisi (più stretti)**.
Testeremo ciascun limite sul seguente **esempio guida**.

Lancia una moneta equa n volte.



Domanda: qual è un **limite di coda** per $P\{\text{almeno } \frac{3}{4}n \text{ volte testa}\}$?

Disuguaglianza di Markov

Teorema: (Markov) Sia X una v.c. non negativa, con media finita $\mu = E[X]$, allora $\forall a > 0$,

$$P\{X \geq a\} \leq \frac{\mu}{a}$$

Dim.:

$$\begin{aligned} E[X] &= \sum_{x=0}^{\infty} x \cdot p_X(x) \geq \sum_{x=a}^{\infty} x \cdot p_X(x) \\ &\geq \sum_{x=a}^{\infty} a \cdot p_X(x) \\ &= a \sum_{x=a}^{\infty} p_X(x) = a \cdot P\{X \geq a\} \end{aligned}$$

Disuguaglianza di Markov sull'esempio guida

Lancia una moneta equa n volte.



Domanda: qual è un **limite di coda** per $P\{\text{almeno } \frac{3}{4}n \text{ volte testa}\}$?

$$X = \text{Numero testa} \sim \text{Binomiale}\left(n, \frac{1}{2}\right) \quad \mu = E[X] = \frac{n}{2}$$

$$P\left\{X \geq \frac{3}{4}n\right\} \leq \frac{\mu}{\frac{3}{4}n} = \frac{\frac{n}{2}}{\frac{3}{4}n} = \frac{2}{3}$$

Chiaramente un limite pessimo,
perché **non dipende da n** .

Disuguaglianza di Chebyshev

Teorema: (Chebyshev) Sia X una v.c. con media finita, μ , e varianza finita. Allora $\forall a > 0$,

$$P\{|X - \mu| \geq a\} \leq \frac{\text{Var}(X)}{a^2}$$

Dim.:

$$P\{|X - \mu| \geq a\} = P\{(X - \mu)^2 \geq a^2\}$$

$$\leq \frac{E[(X - \mu)^2]}{a^2}$$

$$= \frac{\text{Var}(X)}{a^2}$$

Dove si applica Markov in questa prova?

Disuguaglianza di Chebyshev sull'esempio guida

Lancia una moneta equa n volte.



Domanda: qual è un **limite di coda** per $P\{\text{almeno } \frac{3}{4}n \text{ volte testa}\}$?

$$X = \text{Numero Teste} \sim \text{Binomiale}\left(n, \frac{1}{2}\right) \quad \mu = E[X] = \frac{n}{2} \quad \text{Var}(X) = \frac{n}{4}$$

$$P\left\{X \geq \frac{3}{4}n\right\} = P\left\{X - \frac{n}{2} \geq \frac{n}{4}\right\} = \frac{1}{2} P\left\{\left|X - \frac{n}{2}\right| \geq \frac{n}{4}\right\} \leq \frac{1}{2} \cdot \frac{\text{Var}(X)}{\left(\frac{n}{4}\right)^2} = \frac{1}{2} \cdot \frac{\frac{n}{4}}{\left(\frac{n}{4}\right)^2} = \frac{2}{n}$$

Perché?

Perché la binomiale è
simmetrica rispetto alla
media se $p=1/2$

Almeno
ora
decrese
con n

Chernoff Bound

Nel ricavare la disuguaglianza di Chebyshev, abbiamo **elevato al quadrato la v.c.** e poi **applicato la disuguaglianza di Markov**.


Nel ricavare la disuguaglianza **di Chernoff**, **esponenziamo la v.c.** e poi **appliciamo la disuguaglianza di Markov**.

$\forall t > 0$:

$$\begin{aligned} P\{X \geq a\} &= P\{tX \geq ta\} \\ &= P\{e^{tX} \geq e^{ta}\} \\ &\leq \frac{E[e^{tX}]}{e^{ta}} \end{aligned}$$

Perché possiamo applicare la disuguaglianza di Markov qui?

Ma poiché questa disuguaglianza vale per **ogni** t , vale anche per il valore di t che la **minimizza**.



Chernoff Bound

Nel ricavare la disuguaglianza di Chebyshev, abbiamo **elevato al quadrato la v.c.** e poi **applicato la disuguaglianza di Markov**.

Nel ricavare il **limite di Chernoff**, esponenziamo la v.c. e poi **appliciamo la disuguaglianza di Markov**.

$$\begin{aligned}\forall t > 0: \quad P\{X \geq a\} &= P\{tX \geq ta\} = P\{e^{tX} \geq e^{ta}\} \\ &\leq \frac{E[e^{tX}]}{e^{ta}}\end{aligned}$$

Teorema 18.3: (Chernoff bound) Sia X una v.c. e a una costante. Allora

$$P\{X \geq a\} \leq \min_{t>0} \left\{ \frac{E[e^{tX}]}{e^{ta}} \right\}$$

Chernoff Bound sulla c.d.f.

Cosa facciamo se siamo interessati a $P\{X \leq a\}$?

$\forall t < 0$:

$$\begin{aligned} P\{X \leq a\} &= P\{tX \geq ta\} \\ &= P\{e^{tX} \geq e^{ta}\} \\ &\leq \frac{E[e^{tX}]}{e^{ta}} \end{aligned}$$

Consideriamo
 $t < 0$



Teorema: (Chernoff bound sulla c.d.f.) Sia X una v.c. e a una costante. Allora

$$P\{X \leq a\} \leq \min_{t < 0} \left\{ \frac{E[e^{tX}]}{e^{ta}} \right\}$$

Chernoff Bound per Binomiale

Teorema 18.4: (Chernoff Bound per la Binomiale)

Sia $X \sim \text{Binomiale}(n, p)$ dove $\mu = \mathbf{E}[X] = np$. Allora, per ogni $\delta > 0$,

$$P\{X - np \geq \delta\} \leq e^{-2\delta^2/n}$$

$$P\{X - np \leq -\delta\} \leq e^{-2\delta^2/n}$$

Lo dimostreremo tra poco, proviamo prima ad
applicarlo!



È più forte quando $\delta = \Theta(n)$.

Chernoff Bound sull'esempio guida

Lancia una moneta equa n volte.



Domanda: qual è un **limite di coda** per $P\{\text{almeno } \frac{3}{4}n \text{ volte testa}\}$?

$$X = \text{Numero teste} \sim \text{Binomiale}\left(n, \frac{1}{2}\right) \quad \mu = E[X] = \frac{n}{2}$$

$$P\left\{X \geq \frac{3}{4}n\right\} = P\left\{X - \frac{n}{2} \geq \frac{n}{4}\right\} \leq e^{-2\left(\frac{n}{4}\right)^2 \cdot \frac{1}{n}} = e^{-\frac{n}{8}}$$

Notare $\delta = \frac{n}{4} = \Theta(n)$

Decresce
esponenzialmente
in n .

Confrontiamo

Lancia una moneta equa n volte.



Domanda: qual è un **limite di coda** per $P\{\text{almeno } \frac{3}{4}n \text{ volte testa}\}$?

Qual è il risultato esatto?

$$P\left\{X \geq \frac{3}{4}n\right\} = \sum_{i=\frac{3}{4}n}^n \binom{n}{i} \left(\frac{1}{2}\right)^i \left(\frac{1}{2}\right)^{n-i} = 2^{-n} \sum_{i=\frac{3}{4}n}^n \binom{n}{i}$$

Teorema del limite centrale

Lancia una moneta equa n volte.



Domanda: qual è un **limite di coda** per $P\{\text{almeno } \frac{3}{4}n \text{ volte testa}\}$?

$$X \sim \text{Binomiale}\left(n, \frac{1}{2}\right)$$

$$\mu = E[X] = \frac{n}{2}$$

$$\text{Var}(X) = \frac{n}{4}$$

$$\sigma_X = \sqrt{\frac{n}{4}}$$

$$P\left\{X \geq \frac{3}{4}n\right\} = P\left\{X - \frac{n}{2} \geq \frac{n}{4}\right\}$$

$$= P\left\{\frac{X - \frac{n}{2}}{\sqrt{\frac{n}{4}}} \geq \frac{\frac{n}{4}}{\sqrt{\frac{n}{4}}}\right\}$$

$$\approx P\left\{\text{Normal}(0,1) \geq \sqrt{\frac{n}{4}}\right\} = 1 - \Phi\left(\sqrt{\frac{n}{4}}\right)$$

Possiamo
applicare CLT perché
sommiamo i.i.d.

Teorema del limite centrale

Lancia una moneta equa n volte.




Domanda: qual è un **limite di coda** per $P\{\textit{almeno } \frac{3}{4}n \textit{ volte testa}\}$?

$$\begin{aligned} P\left\{X \geq \frac{3}{4}n\right\} &= 1 - \Phi\left(\frac{\sqrt{n}}{2}\right) = 1 - \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\sqrt{n}/2} e^{-t^2/2} dt \\ &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-t^2/2} dt - \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\sqrt{n}/2} e^{-t^2/2} dt \\ &= \frac{1}{\sqrt{2\pi}} \int_{\sqrt{n}/2}^{\infty} e^{-t^2/2} dt \approx \frac{2}{\sqrt{2\pi n}} e^{-n/8}. \end{aligned}$$

Attenzione. Con il CLT
si ottiene una
approssimazione, non
un **limite superiore**


Confrontiamo



Confrontiamo

Ingrandimento
sui valori più alti
di $n > 70$.

Chebyshev non
è più visibile.
È troppo alto.



Persino
Chernoff non
sembra più
tanto efficace

Chebyshev



Exact



Chernoff



Normal



Chernoff Bound per la Binomiale

Teorema 18.4: (Chernoff Bound per la Binomiale)

Sia $X \sim \text{Binomiale}(n, p)$ dove $\mu = \mathbf{E}[X] = np$. Allora, per ogni $\delta > 0$,

$$\begin{aligned} P\{X - np \geq \delta\} &\leq e^{-2\delta^2/n} \\ P\{X - np \leq -\delta\} &\leq e^{-2\delta^2/n} \end{aligned}$$

Dimostriamo la prima disuguaglianza del teorema.

Useremo il seguente risultato.

Lemma 18.5: Per ogni $t > 0$ e $0 < p < 1$ e $q = 1 - p$, abbiamo:

$$pe^{tq} + qe^{-tp} \leq e^{t^2/8}$$

Chernoff Bound per la Binomiale

Teorema 18.4: Sia $X \sim \text{Binomiale}(n, p)$ dove $\mu = E[X] = np$. Allora, per ogni $\delta > 0$,

$$P\{X - np \geq \delta\} \leq e^{-2\delta^2/n}$$

Dim: Per ogni $t > 0$,

$$\begin{aligned} P\{X - np \geq \delta\} &= P\{t(X - np) \geq t\delta\} \\ &= P\{e^{t(X-np)} \geq e^{t\delta}\} \end{aligned}$$



Ricorda che
 $X = \sum_{i=1}^n X_i$ dove
 $X_i \sim \text{Bernoulli}(p)$

$$\begin{aligned} &\stackrel{\text{Markov}}{\leq} e^{-t\delta} E[e^{t(X-np)}] = e^{-t\delta} E[e^{t((X_1-p)+(X_2-p)+\dots+(X_n-p))}] \\ &= e^{-t\delta} E[e^{t(X_1-p)} e^{t(X_2-p)} \dots e^{t(X_n-p)}] = e^{-t\delta} \cdot \prod_{i=1}^n E[e^{t(X_i-p)}] \end{aligned}$$

indipendenza

Chernoff Bound per la Binomiale

Teorema 18.4: Sia $X \sim \text{Binomiale}(n, p)$ dove $\mu = E[X] = np$. Allora, per ogni $\delta > 0$,

$$P\{X - np \geq \delta\} \leq e^{-2\delta^2/n}$$

Quindi, per $t > 0$,

$$\begin{aligned} P\{X - np \geq \delta\} &\leq e^{-t\delta} \prod_{i=1}^n E[e^{t(X_i - p)}] \\ &= e^{-t\delta} \prod_{i=1}^n (p \cdot e^{t(1-p)} + (1-p) \cdot e^{-tp}) \\ &= e^{-t\delta} \prod_{i=1}^n (e^{t^2/8}) = e^{-t\delta + nt^2/8} \end{aligned}$$

Per il
Lemma
18.5

Ora dobbiamo trovare il t
che minimizza $e^{-t\delta + nt^2/8}$

Chernoff Bound per la Binomiale

Teorema 18.4: Sia $X \sim \text{Binomiale}(n, p)$ dove $\mu = E[X] = np$. Allora, per ogni $\delta > 0$,

$$P\{X - np \geq \delta\} \leq e^{-2\delta^2/n}$$

Quindi, per $t > 0$,

$$P\{X - np \geq \delta\} \leq e^{-t\delta + nt^2/8}$$

L'esponente è
minimizzato per

$$t = \frac{4\delta}{n}$$

$$\Rightarrow P\{X - np \geq \delta\} \leq e^{-\left(\frac{4\delta}{n}\right)\delta + n\left(\frac{4\delta}{n}\right)^2/8} = e^{-2\delta^2/n}$$

Algoritmi randomizzati

Algoritmi randomizzati

Un algoritmo randomizzato è semplicemente un algoritmo che utilizza una sorgente di bit casuali, che gli consente di compiere scelte o mosse casuali.

Gli algoritmi randomizzati sono estremamente popolari in informatica perché

- (1) sono molto efficienti (hanno tempi di esecuzione ridotti) per ogni input, e
- (2) sono spesso molto semplici.

Las Vegas vs Monte Carlo

Tipi di algoritmi randomizzati

Algoritmi di tipo Las Vegas

Producono sempre la risposta corretta, ma il loro tempo di esecuzione dipende dai bit casuali.

Algoritmi di tipo Monte Carlo

Sono estremamente veloci, indipendentemente dai bit casuali. Tuttavia, restituiscono la risposta corretta solo in una certa frazione dei casi, una frazione che dipende dai bit casuali.

Algoritmi deterministici vs randomizzati

Quando **analizziamo** il tempo di esecuzione di un algoritmo, immaginiamo un **avversario** che sceglie l'input.

Per un **algoritmo deterministico**, la sequenza di passi è sempre la stessa: l'avversario può quindi fornire un **input pessimo**, su cui l'algoritmo impiega molto tempo. Il *runtime* viene quindi definito come il **tempo nel caso peggiore**.

Un **algoritmo randomizzato**, invece, usa **bit casuali** per decidere le proprie mosse. L'avversario può ancora scegliere l'input, ma non può prevedere le scelte casuali dell'algoritmo. Ciò rende **molto più difficile costruire un caso peggiore**. Spesso non c'è un caso peggiore.

Perché algoritmi randomizzati?

Il grande vantaggio degli **algoritmi randomizzati** è che tendono a essere “probabilmente molto efficienti” **per ogni input**.

Gli algoritmi randomizzati risultano spesso **molto più rapidi dei deterministici**, perché **non esiste un input di caso peggiore fisso**. Tuttavia, poiché l'algoritmo dipende dai bit casuali, il **tempo di esecuzione può variare anche sullo stesso input**: il *runtime* è quindi una **variabile casuale**.

Perché algoritmi randomizzati?

Un ulteriore vantaggio degli **algoritmi randomizzati** è che sono spesso **molto più semplici** degli algoritmi deterministici.

In molti casi, questi algoritmi possono sembrare **quasi “banali” o ingenuamente semplici**, eppure **funzionano sorprendentemente bene** e sono **facili da descrivere e da implementare**.

Presentiamo ora alcuni esempi di **algoritmi di tipo Las Vegas**, che producono **sempre la risposta corretta**.

Quicksort deterministico

Quicksort è un algoritmo efficiente per ordinare una lista di n numeri $a_1, a_2, \dots, a_n$. Per semplicità, assumiamo che tutti i numeri siano **distinti**.

La **dimensione del problema** è il numero di elementi da ordinare, cioè n .

Il **tempo di esecuzione** è misurato dal **numero di confronti** necessari per ordinare la lista.


$$C(n) = \text{numero di confronti necessari quando la dimensione è } n.$$

Il **primo elemento** a_1 viene scelto come **pivot**. Tutti gli altri elementi vengono confrontati con il pivot:

- quelli **minori** formano la lista L_1 ,
- quelli **maggiori** formano la lista L_2 .

Quicksort deterministico

Dopo la prima suddivisione, la lista diventa:




L'algoritmo **Quicksort** viene poi applicato **ricorsivamente**:

su L_1 per ottenere la sua versione ordinata L_1^S ;

su L_2 per ottenere L_2^S .

Il caso base corrisponde ad una lista di un solo elemento (banalmente già ordinata).

Infine, la lista ordinata risultante è:



Quicksort deterministico

Domanda: Qual è un esempio di *input sfavorevole* per il Quicksort deterministico?

Risposta: Una **lista già ordinata** (in modo crescente o decrescente).

In questo caso, il pivot scelto (il primo elemento) è sempre **il più piccolo**, e tutti gli altri elementi finiscono **nella stessa sottolista** (L_1 o L_2).

La dimensione del problema quindi **si riduce molto lentamente**, producendo un **tempo di esecuzione elevato** ($\Theta(n^2)$).

Quicksort deterministico

Idealmente, vorremmo che il **pivot** fosse sempre **la mediana** della lista.

In questo modo, la lista verrebbe suddivisa in **due parti di dimensione uguale**, garantendo un **tempo di esecuzione ottimale**.

La ricorrenza per il numero di confronti è

$$\begin{aligned} C(n) &= (n - 1) + 2 C(n/2) = (n - 1) + 2 \left(\frac{n}{2} - 1 + 2C(n/4) \right) \\ &= (n - 1) + (n - 2) + 4 C(n/4) \\ &= (n - 1) + (n - 2) + (n - 4) + 8 C(n/8) \\ &\quad \vdots \\ &= n \log n - (1 + 2 + 4 + 8 + \dots + n/2) \\ &= n \log n - n + 1 = O(n \log n) \end{aligned}$$

supponendo n potenza di 2:
l'asintotico non cambia.

Quicksort randomizzato

Vorremmo che il tempo di esecuzione di **Quicksort** fosse $O(n \log n)$ per **ogni** lista di input.

Ma un avversario può sempre fornirci un **input sfavorevole**, forzando il caso $\Theta(n^2)$.

Soluzione: Quicksort randomizzato.

È identico alla versione deterministica, tranne che il **pivot è scelto a caso a ogni passo**. Così l'avversario **non può costruire sistematicamente** una lista “cattiva”: è proprio questo il vantaggio della **casualità**.

Quicksort randomizzato: analisi

Teorema: Data una lista input di n elementi distinti, **Quicksort randomizzato** effettua $E[C(n)] = O(n \log n)$ confronti **in valore atteso**.

Dim.: Sia l'input $a_1, a_2, \dots, a_n$ e sia $s_1 < s_2 < \dots < s_n$ la versione **ordinata** di questi elementi (assunti **distinti**).


$$X_{ij} = \begin{cases} 1 & \text{se } s_i \text{ e } s_j \text{ vengono confrontati durante l'esecuzione.} \\ 0 & \text{altrimenti.} \end{cases}$$

Osservazione: ogni coppia (s_i, s_j) può essere confrontata **al più una volta**.

Quicksort randomizzato: analisi

Il numero totale di confronti è

$$C(n) = \sum_{i=1}^{n-1} \sum_{j=i+1}^n X_{ij}.$$



Qual è la probabilità che s_i e s_j vengano confrontati?

E per la linearità del valore atteso:

$$E[C(n)] = \sum_{i=1}^{n-1} \sum_{j=i+1}^n E[X_{ij}] = \sum_{i=1}^{n-1} \sum_{j=i+1}^n P\{X_{ij} = 1\}.$$

Quicksort randomizzato: analisi

Qual è la probabilità che s_i e s_j vengano confrontati?

Fissata la coppia (s_i, s_j) , consideriamo S l'insieme degli elementi i cui valori si trovano tra s_i e s_j :

$$S = \{s_i, s_{i+1}, \dots, s_j\}.$$

Finché nessun elemento di S è stato scelto come pivot, tutti gli elementi di S rimangono **nella stessa partizione corrente** dell'algoritmo.

Il **primo pivot** scelto in S deciderà se s_i e s_j si confronteranno o meno.

Quicksort randomizzato: analisi

Il **primo pivot** scelto in S deciderà se s_i e s_j si confronteranno o meno.

- Se il primo pivot in S è **uno dei due estremi**, s_i o s_j , allora verranno confrontati.
- Se il pivot è un elemento “interno”, allora saranno separati per sempre.

Poiché il pivot è scelto **uniformemente a caso** tra gli $|S| = j - i + 1$ elementi, la probabilità che sia s_i o s_j è:

$$\Pr(X_{ij} = 1) = \frac{2}{j - i + 1}.$$

Quicksort randomizzato: analisi

$$E[C(n)] = \sum_{i=1}^{n-1} \sum_{j=i+1}^n E[X_{ij}] = \sum_{i=1}^{n-1} \sum_{j=i+1}^n \frac{2}{j-i+1}$$

$$= 2 \sum_{i=1}^{n-1} \sum_{k=2}^{n-i+1} \frac{1}{k}$$

poniamo $k = j - i + 1$

$$\leq 2 \sum_{i=1}^n \sum_{k=2}^n \frac{1}{k} = 2 \sum_{i=1}^n \left(\sum_{k=1}^n \frac{1}{k} - 1 \right)$$

$$H_n = 1 + \frac{1}{2} + \frac{1}{3} + \dots + \frac{1}{n} \\ \leq 1 + \ln n$$

$$< 2 \sum_{i=1}^n (1 + \ln n - 1) = 2n \ln n$$

Quicksort deterministico vs randomizzato

Quicksort deterministico.

il **pivot** è **deterministicamente assegnato** (e.g. primo elemento)

→ esiste un **input pessimo** che richiede $O(n^2)$

Quicksort randomizzato.

il **pivot** è **scelto a caso** a ogni passo,

→ **non esiste un caso peggiore:**
il tempo di esecuzione medio (rispetto alla scelta casuale del pivot) è $O(n \log n)$.

Possiamo ora usare **Chernoff** per dimostrare che, **con alta probabilità** ($\geq 1 - \frac{1}{n}$),

Randomized Quicksort richiede solo $O(n \lg n)$ confronti.