# Richiami di probabilità Informale

Paolo D'Arco pdarco@unisa.it

Università di Salerno

Elementi di Crittografia

## Contenuti

- Nozioni di base
- 2 Alcuni risultati e qualche bound
- 3 Variabili casuali e due disuguaglianze
- 4 Algoritmi e variabili casuali

 $\Omega$ : insieme di tutti i possibili risultati di un esperimento (eventi elementari)

Un evento E è un sottoinsieme di  $\Omega$ 

Una probabilità è un modo di assegnare ad ogni evento un valore tra 0 e 1 con la condizione che l'evento  $\Omega$  ha probabilità 1. Precisamente, per ogni  $E \subseteq \Omega$ , risulta

$$Pr(E) \geq 0$$
 e  $Pr(\Omega) = 1$ .

Inoltre, se  $E_1$  ed  $E_2$  sono mutualmente esclusivi, cioè non hanno risultati "in comune", allora

$$Pr(E_1 \vee E_2) = Pr(E_1) + Pr(E_2).$$

Se  $\bar{E} = \Omega \setminus E$  indica il complemento di  $E \subseteq \Omega$ , allora

$$Pr(\bar{E}) = 1 - Pr(E).$$



Se  $E_1$  ed  $E_2$  sono eventi, allora

$$Pr(E_1 \wedge E_2) \leq Pr(E_1).$$

mentre,

$$Pr(E_1 \vee E_2) \geq Pr(E_1)$$
 e  $Pr(E_1 \vee E_2) \leq Pr(E_1) + Pr(E_2)$ .

In generale, dati k eventi, vale il seguente risultato (union bound)

$$Pr(\bigvee_{i=1}^k E_i) \leq \sum_{i=1}^k Pr(E_i).$$

La probabilità condizionata di  $E_1$  dato  $E_2$ , denotata con  $Pr(E_1|E_2)$ , è definita come

$$Pr(E_1|E_2)\stackrel{def}{=} rac{Pr(E_1 \wedge E_2)}{Pr(E_2)}, \qquad ext{dove } Pr(E_2) > 0.$$

Segue che:

$$Pr(E_1 \wedge E_2) = Pr(E_1|E_2) \cdot Pr(E_2).$$

**Teorema di Bayes**. Se  $Pr(E_2) \neq 0$ , allora

$$Pr(E_1|E_2) = \frac{Pr(E_2|E_1) \cdot Pr(E_1)}{Pr(E_2)}.$$

Dim.

$$Pr(E_1|E_2) = \frac{Pr(E_1 \wedge E_2)}{Pr(E_2)} = \frac{Pr(E_2 \wedge E_1)}{Pr(E_2)} = \frac{Pr(E_2|E_1) \cdot Pr(E_1)}{Pr(E_2)}.$$

Gli eventi  $E_1$  ed  $E_2$  sono probabilisticamente indipendenti se

$$Pr(E_1 \mid E_2) = Pr(E_1).$$

Il verificarsi di  $E_2$ , cioè, non cambia la probabilità che si verifichi  $E_1$ .

Nota che, se  $E_1$  ed  $E_2$  sono indipendenti, risulta

$$Pr(E_1) = Pr(E_1 \mid E_2) = \frac{Pr(E_1 \land E_2)}{Pr(E_2)}$$

che implica:

$$Pr(E_1 \wedge E_2) = Pr(E_1) \cdot Pr(E_2).$$

Diremo che gli eventi  $E_1, E_2, \ldots, E_n$  costituiscono una partizione di  $\Omega$  se

$$Pr(E_1 \vee E_2 \vee ... \vee E_n) = 1$$
 e per ogni  $i \neq j, Pr(E_i \wedge E_j) = 0$ .

In tal caso, per qualsiasi  $F \subseteq \Omega$ , risulta

$$Pr(F) = \sum_{i=1}^{n} Pr(F \wedge E_i).$$

Nel caso in cui n=2, risulta  $E_2=\bar{E}_1$  e quindi

$$Pr(F) = Pr(F \wedge E_1) + Pr(F \wedge E_2)$$

$$= Pr(F \wedge E_1) + Pr(F \wedge \bar{E}_1)$$

$$= Pr(F \mid E_1) \cdot Pr(E_1) + Pr(F \mid \bar{E}_1) \cdot Pr(\bar{E}_1).$$

Prendendo  $F = E_1 \lor E_2$ , per qualsiasi  $E_2$ , otteniamo una limitazione *migliore* dell'union bound

$$Pr(E_1 \vee E_2) = Pr(E_1 \vee E_2 \mid E_1) \cdot Pr(E_1) + Pr(E_1 \vee E_2 \mid \bar{E}_1) \cdot Pr(\bar{E}_1)$$
  
\$\leq Pr(E\_1) + Pr(E\_2 \cong \bar{E}\_1).\$

Estendendo il risultato agli eventi  $E_1, E_2, \dots, E_n$ , vale il seguente

$$Pr(\bigvee_{i=1}^n E_i) \leq Pr(E_1) + \sum_{i=2}^n Pr(E_i \mid \bar{E}_1 \wedge \ldots \wedge \bar{E}_{i-1}).$$

## Problema del compleanno

Se scegliamo q elementi  $y_1, \ldots, y_q$  uniformemente a caso da un insieme di taglia N, qual è la probabilità che esistano i e j distinti tali che  $y_i = y_j$  (collisione)?

Indichiamo la probabilità dell'evento con coll(q, N).

Problema del compleanno: quanto deve essere numeroso un gruppo di persone affinchè, con probabilità almeno 1/2, due di esse siano nate lo stesso giorno?

## Problema del compleanno

#### Corrispondenza:

- assumendo che i compleanni siano uniformemente distribuiti e che N=365
- $y_i$  rappresenti il compleanno della persona i-esima nel gruppo  $y_1, \dots, y_q$

la soluzione al problema del compleanno consiste nel trovare

il minimo q per cui risulta  $coll(q, 365) \ge 1/2$ 

Sorprendentemente q = 23 è sufficiente.

# Upper bound

**Lemma** A.15. Sia N un intero positivo fissato, e siano  $y_1, \ldots, y_q$  q elementi scelti indipendentemente ed uniformemente da un insieme di taglia N. La probabilità che esistano i e j distinti per cui  $y_i = y_j$  è

$$coll(q, N) \leq q^2/2N$$
.

Dim. Applichiamo l'union bound. Sia

- Coll l'evento che denota una collisione
- $Coll_{i,j}$  l'evento  $y_i = y_j$

Per le assunzioni fatte,  $Pr[Coll_{i,j}] = 1/N$  per ogni i e j distinti e  $Coll = \bigvee_{i \neq j} Coll_{i,j}$ . Pertanto,

$$Pr[\mathit{Coll}] = Pr[\bigvee_{i \neq j} \mathit{Coll}_{i,j}] \leq \sum_{i \neq j} Pr[\mathit{Coll}_{i,j}] = \binom{q}{2} \cdot \frac{1}{N} \leq \frac{q^2}{2N}.$$

#### Lower bound

**Lemma** A.15. Sia N un intero positivo fissato, e siano  $y_1, \ldots, y_q$   $q \leq \sqrt{2N}$  elementi scelti indipendentemente ed uniformemente da un insieme di taglia N. Allora la probabilità che esistano i e j distinti tali che  $y_i = y_j$  è

$$coll(q, N) \geq 1 - e^{-\frac{q \cdot (q-1)}{2N}} \geq \frac{q \cdot (q-1)}{4N}.$$

**Dim.** Consultate l'Appendice A del libro di testo.

Conclusione: se  $q = \Theta(\sqrt{N})$ , la probabilità di avere una collisione è *costante*.

### Variabili casuali

Variabile casuale: variabile che può assumere un insieme di differenti valori, ciascuno con una probabilità associata.

I valori vengono assunti in accordo al risultato dell'esperimento sottostante. Più formalmente

$$X:\Omega\rightarrow S$$

dove  $\Omega$  è lo spazio degli eventi elementari con relative probabilità ed S un insieme di valori.

Solitamente S è un insieme finito di numeri reali.

Se X non assume valori negativi, è detta non negativa.

Se  $S = \{0, 1\}$ , X viene detta variabile casuale 0/1 (o binaria).

Il concetto può essere esteso al caso più generale in cui S contiene altri elementi: vettori, sequenze, matrici ...

#### Valore medio

Diremo che le variabili casuali 0/1  $X_1, \ldots, X_k$  sono indipendenti se, per tutti i  $b_1, \ldots, b_k$ , vale che

$$Pr[X_1 = b_1 \wedge \ldots \wedge X_k = b_k] = \prod_{i=1}^k Pr[X_i = b_i].$$

Il valore medio Exp(X) della variabile casuale X è definito come

$$Exp(X) = \sum_{s \in S} Pr[X = s] \cdot s.$$

Nota che può essere un valore  $\notin S$ .

Il valore medio soddisfa la proprietà di linearità. Date le variabili casuali  $X_1, \ldots, X_k$  risulta:

$$Exp[\sum_{i=1}^{k} X_i] = \sum_{i=1}^{k} Exp[X_i].$$

## Disuguaglianza di Markov

Se  $X_1$  e  $X_2$  sono indipendenti

$$Exp(X_1X_2) = Exp(X_1) \cdot Exp(X_2).$$

Quando "si sa poco" di una variabile casuale, la disuguaglianza di Markov risulta utile.

**Disuguaglianza di Markov.** Sia X una variabile casuale non negativa, e sia v>0. Allora

$$Pr[X \ge v] \le \frac{Exp[X]}{v}.$$

**Dim.** Supponiamo X assuma valori in S. Risulta:

$$Exp[X] = \sum_{s \in S} Pr[X = s] \cdot s$$

$$\geq \sum_{s \in S, s < v} Pr[X = s] \cdot 0 + \sum_{s \in S, s \geq v} Pr[X = s] \cdot v$$

$$\geq v \cdot Pr[X \geq v].$$

#### Varianza

La varianza di una variabile causale X, denotata con Var[X], misura quanto X devia dal valore medio.

$$Var[X] \stackrel{\text{def}}{=} Exp[(X - Exp[X])^2] = Exp[X^2] - Exp[X]^2.$$

Si può facilmente mostrare che

$$Var[aX + b] = a^2 Var[X].$$

Inoltre, per variabili causali 0/1  $X_i$  risulta  $Var[X_i] \le 1/4$  perchè in questo caso  $Exp[X_i] = Exp[X_i^2]$  e quindi

$$Exp[X_i^2] - Exp[X_i]^2 = Exp[X_i](1 - Exp[X_i])$$

che ha valore massimo per  $Exp[X_i] = 1/2$  da cui  $Var[X_i] \le 1/4$ .

# Disuguaglianza di Chebychev

**Disuguaglianza di Chebychev**. Sia X una variabile casuale e sia  $\delta > 0$ . Allora

$$Pr[|X - Exp[X]| \ge \delta] \le \frac{Var[X]}{\delta^2}.$$

Dim. Applicando la disuguaglianza di Markov.

# Un po' di esempi semplici

Sia  $\Omega = \{T, C\}$  (lancio di una moneta). Esempi di distribuzioni sono:

$$Pr[T] = 1/2$$
  $Pr[C] = 1/2$   $\Rightarrow Pr[\Omega] = 1$  (distribuzione uniforme)

$$Pr[T] = 1/4$$
  $Pr[C] = 3/4$   $\Rightarrow Pr[\Omega] = 1$  (distribuzione non uniforme)

In generale, se S è un insieme finito di valori e

$$X:\Omega \to S$$
 è tale che  $Pr[X=s]=rac{1}{|S|}$   $\forall s \in S,$ 

la distribuzione di probabilità si dice *uniforme* e la variabile aleatoria si dice *uniformemente distribuita*.

Sia A un algoritmo probabilistico (o randomizzato, cioè che usa random bit).

Le variabili casuali sono utili per rappresentare l'output di A.

Precisamente, la variabile casuale A rappresenta i possibili valori - con relative probabilità - che l'algoritmo A può dare in output, a seconda delle scelte casuali che compie.

#### In uno schema di cifratura

- $Gen() \rightarrow k \in K$  (spazio delle chiavi)
  - la variabile casuale K può essere usata per rappresentare i possibili
     k ∈ K che l'algoritmo di generazione delle chiavi può dare in output, a seconda delle scelte casuali che effettua
- $Enc_k(m) \rightarrow c \in C$  (spazio dei cifrati)
  - la variabile casuale  $C_{k,m}$  può essere usata per rappresentare i possibili  $c \in C$  che, dati k ed m, l'algoritmo di cifratura può dare in output, a seconda delle scelte casuali che effettua

Nota: se siamo interessati a valutare la probabilità dei cifrati in generale (non per una specifica chiave ed uno specifico messaggio) utilizziamo la variabile casuale C definita da

$$Pr[C = c] = Pr[Enc_{\mathsf{K}}(\mathsf{M}) = c]$$

La distribuzione di C dipende dalle distribuzioni di K ed M e dalle scelte casuali che l'algoritmo di cifratura effettua.

$$Pr[C = c] = \sum_{k \in K} \sum_{m \in M} Pr[Enc_k(m) = c | K = k, M = m] \cdot Pr[K = k \land M = m]$$

$$\downarrow \downarrow C_{k,m}$$

Nelle analisi nel testo non confondete oggetti diversi (e.g.,  $Enc_K(M)$  con  $Enc_k(m)$ ).

Sia ancora  $\Omega = \{T, C\}$ . Un altro esempio di distribuzione è:

$$Pr[T] = 1$$
  $Pr[C] = 0$   $\Rightarrow Pr[\Omega] = 1$  (distribuzione degenere)

Un algoritmo deterministico può essere visto come un caso particolare degli algoritmi probabilistici, in cui la distribuzione di probabilità della variabile casuale che rappresenta l'output è degenere, i.e., ha valore 1 in un punto e 0 in tutti gli altri.

# Famiglie di distribuzioni\*

Una famiglia di distribuzioni (distribution ensemble) è una famiglia di distribuzioni di probabilità o variabili casuali

$$X = \{X_i\}_{i \in I},$$
 dove

- X<sub>i</sub> denota una distribuzione di probabilità o variabile casuale
- *i* è l'indice che denota la *i*-esima distribuzione
- I è l'insieme degli indici e può essere
  - un sottoinsieme degli interi
  - un insieme di stringhe
  - un generico insieme contabile

# Famiglie di distribuzioni\*: perchè...

**Studio degli algoritmi**: utilizziamo l'analisi asintotica per capire, al crescere della taglia dell'input, come si comportano gli algoritmi progettati.

• e.g., si pensi agli algoritmi di ordinamento e all'analisi della loro efficienza in funzione del numero di elementi da ordinare

**Crittografia**: valuteremo *asintoticamente* il comportamento degli schemi crittografici al crescere di un parametro, detto *parametro di sicurezza*, passato come input allo schema.

Pertanto, al variare del parametro di sicurezza, avremo una famiglia di schemi e, per modellarne il comportamento, avremo bisogno di una famiglia di distribuzioni.

Nota: in buona parte del testo tuttavia la presentazione viene semplificata e le famiglie di distribuzioni non vengono usate.

## Qualche esempio di ensemble

Consideriamo l'insieme  $\{0,1\}^n$  delle stringhe di n bit. L'ensemble

$$\{U_n\}_{n\in\mathbb{N}}$$

rappresenta l'ensemble che contiene le distribuzioni di probabilità uniformi sugli insiemi di stringhe lunghe n bit

$$\begin{array}{c|ccccc} U_1 & 0 & 1 \\ prob & 1/2 & 1/2 \\ \hline \\ U_2 & 00 & 01 & 10 & 11 \\ prob & 1/4 & 1/4 & 1/4 & 1/4 \\ & & \cdots \\ U_n & 00 \dots 0 & \dots & 11 \dots 1 \\ prob & 1/2^n & 1/2^n \\ \hline \end{array}$$

# Qualche esempio di ensemble

Un esempio invece diverso dall'ensemble uniforme è il seguente. Sia

$$\{P_n\}_{n\in N}$$

l'ensemble delle distribuzioni di probabilità su  $\{0,1\}^n$  che associano probabilità uniforme alle prime  $2^{n-1}$  stringhe e 0 alle restanti

$$egin{array}{c|cccc} P_1 & 0 & 1 & & & \\ prob & 1 & 0 & & & & \\ \hline P_2 & 00 & 01 & 10 & 11 & \\ prob & 1/2 & 1/2 & 0 & 0 & & \\ & & & & & & \\ \hline \end{array}$$

$$P_n \mid 00...0 \quad ... \quad 01...1 \quad 10...0 \quad ... \quad 11...1$$
 $prob \mid 1/2^{n-1} \quad 1/2^{n-1} \quad 0 \quad 0$