Fondamenti di Data Science e Machine Learning - Prof. G. Polese - Anno Accademico 2020/21

Prova Scritta (ore 9:00) 14/07/2021

First Name and Last Name:

University ID(Matricola):

Esercizio 1 (punti 5 su 30)

Disegnare un percettrone, eventualmente multilivello, con indicazione dei pesi e delle step function, che calcoli la funzione booleana (A AND B) XOR (C OR D).

Esercizio 2 (punti 6 su 30)

Data la seguente espressione:

$$2X^2Y + 3XY + 4$$

- a) Disegnare il grafo TensorFlow dell'espressione
- b) Scrivere il codice Python relativo al grafo del punto a), inizializzando la variabile X a 5 ed Y a 7, creando una sessione, valutando l'espressione ed infine chiudendo la sessione.

Esercizio 3 (punti 5 su 30)

Disegnare la struttura a lattice per l'estrazione di dipendenze funzionali da un dataset con 6 attributi, indicando il numero totale di dipendenze candidate.

Esercizio 4 (punti 7 su 30)

Data la seguente signature matrix:

Shingle	S ₁	S ₂	S ₃	S ₄	S ₅
0	1	1	0	0	0
1	0	1	1	1	1
2	0	0	0	1	0
3	0	1	0	0	1
4	1	1	0	1	1
5	0	0	1	1	0
6	1	0	1	0	1
7	0	0	1	1	0

a) (4 punti) Calcolare la signature di ogni colonna usando le seguenti 6 funzioni hash:

$$h1(x) = (4x^2 + 3) \mod 8$$
; $h2(x) = (2x^3 + 7) \mod 8$; $h3(x) = (3x^4 + 5) \mod 8$;

$$h4(x) = (5x^2 - 2) \mod 8$$
; $h5(x) = (7x - 3) \mod 8$; $h6(x) = (6x^3 + 8) \mod 8$;

Mostrare l'evoluzione della matrice delle signature di minhash simulando l'esecuzione dell'algoritmo per il loro calcolo. Inoltre, calcolare le similarità di Jaccard tra tutte le coppie di signature di minhash.

b) (3 *punti*) Sulla base delle similarità di Jaccard calcolate al punto b), suddividere la matrice delle signature in bande (2 da 3 o 3 da 2) in modo tale da ridurre la probabilità di falsi positivi nella selezione dei documenti da confrontare.

Fondamenti di Data Science e Machine Learning - Prof. G. Polese - Anno Accademico 2020/21 Prova Scritta (ore 9:00) 14/07/2021

Esercizio 5 (punti 7 su 30)

Dati i seguenti punti in uno spazio bidimensionale: (1, 2)(3, 7)(5, 14)(7, 5)(2, 10)(4, 3)(6, 2)

Usare l'algoritmo *K-means* per suddividere tali punti in 2 cluster, utilizzando la L3 norm e svolgendo 3 iterazioni dell'algoritmo. Per la scelta dei 2 centroidi, alla prima iterazione utilizzare il metodo che prevede la selezione del punto più vicino al centroide di tutti i punti forniti e quello più lontano da quest'ultimo.